Implementačná dokumentácia k 1. úlohe do IPP 2020/2021

Meno a priezvisko: Jakub Bartko Login: xbartk07

1 Štruktúra kódu

Činnosť skriptu parser.php je možné rozdeliť na spracovanie argumentov príkazového riadka, načítavanie zdrojového kódu, lexikálnu a syntaktickú analýzu inštrukcií, generovanie výstupu vo formáte XML a zbieranie štatistík o zdrojovom kóde. Hlavné súčasti týchto činností sú rozdelené na niekoľko hlavných funkcií, ktoré ďalej využívajú pomocné obslužné funkcie a štruktúry.

Medzi tieto štruktúry patria:

- trieda State jednoduchý zoznam stavov konečného automatu, ktorým je parser riadený
- trieda Counters počítadlá riadkov kódu, komentárov, . . . a pomocné zoznamy návestí; slúžiace na zber štatistík
 pre rozšírenie STATP
- asociatívne pole opcodes zoznam platných inštrukcií zdrojového kódu a typov ich argumentov (variable, symbol alebo label)
- asociatívne pole opts zoznam zadaných súborov štatistík a príslušných cieľových súborov

Okrem toho je výstup vo formáte XML zbieraný v premennej [string] outputs v rôznych bodoch parsovania.

2 Činnosť parsera

Argumenty príkazového riadka sú spracované iterovaním, kontrolou správnosti s využitím regulárnych výrazov a generovaním asociatívneho poľa opts pre príslušné súbory štatistík.

Parsovanie zdrojového kódu je v základe štruktúrované ako primitívny konečný automat. V každom svojom cykle načíta jeden riadok zo štandardného vstupu, odstráni z neho komentáre a riadok preskočí, ak obsahuje výhradne biele znaky. Ako prvý neprázdny riadok musí spracovať hlavičku zdrojového kódu; ďalej spracováva inštrukcie a ich argumenty.

Spracovanie inštrukcie pozostáva z kontroly jej operačného kódu a kontroly počtu a typu jej argumentov podľa referenčného asociatívneho poľa opcodes, a generovania XML elementu instruction. Obidve z uvedených kontrol sú vykonané s využitím regulárnych výrazov na základe definovaného typu: variable, symbol alebo label. Pri type variable sa skontroluje platnosť označenia rámca a formát identifikátora; pri type symbol sa skontroluje možnosť uvedenia premennej (kontrola identická s typom variable) a uvedenia konštanty, pri ktorej sa skontroluje jej špecifikovaný typ a platnosť príslušnej hodnoty. Okrem toho sa v reťazci, ktorý predstavuje argument inštrukcie, nahradia problémové znaky (pre formát XML) za zodpovedajúce XML entity.

3 Rozšírenie STATP

Štatistiky o zdrojovom kóde sú zbierané na príslušných miestach v skripte — napr. počet riadkov kódu pri prečítaní nového neprázdneho riadku zdrojového kódu zo štandardného vstupu, alebo počet definovaných návestí pri parsovaní inštrukcie s operačným kódom LABEL. Dodatočné spracovanie si však vyžaduje vyhodnotenie počtu rôznych typov skokov (skokov dopredu, dozadu, alebo neplatných skokov). Toto vyhodnotenie je zabezpečené udržiavaním zoznamu definovaných návestí a zoznamu destinácií skokov. Pri inštrukcií s operačným kódom LABEL sa definované návestie uloží do prvého z týchto zoznamov a v prípade, že sa vyskytuje v zozname druhom, pripočíta sa ako skok dopredu. Analogicky sa destinácia skoku pripočíta ako skok dozadu, ak pri inštrukcií podmieneného alebo nepodmieného skoku špecifikované návestie už nachádza v zozname definovaných návestí. Nájdené cieľové návestia sa z príslušného zoznamu odstránia a tie, ktoré v ňom zostanú po prejdení celým zdrojovým programom sú považované za bad jumps. Na záver parsovania je zoznam opts iterovaný a špecifikované súbory štatistík sú zapísané do príslušných súborov.